Statistiques et analyse de données

Informatique — Licence 2 (L2)

Cours INF-L2-13

Institut Africain de Management (IAM) — Bamako, Mali
Bibliothèque Universitaire — Bronbah Tech

À propos de ce cours

Passer des données brutes à la décision : décrire une série statistique, mesurer sa dispersion, modéliser un lien entre deux variables par la régression, raisonner avec la loi normale, puis estimer et tester avec un niveau de confiance annoncé.

Document pédagogique original créé pour les étudiants de l'IAM : leçons détaillées, exemples commentés, travaux dirigés et pratiques, exercices corrigés, QCM d'évaluation et vidéos recommandées. Aucun contenu n'est reproduit d'ouvrages existants.

Sommaire

• Introduction à la matière
• Objectifs d'apprentissage
• Leçon 1 — Rappels : séries statistiques et représentations graphiques
• Leçon 2 — Paramètres de position et paramètres de dispersion
• Leçon 3 — Régression linéaire et corrélation
• Leçon 4 — La loi normale et l'échantillonnage
• Leçon 5 — Estimation et intervalles de confiance
• Leçon 6 — Tests d'hypothèses : initiation
• Leçon 7 — Analyse de données avec le tableur et avec Python
• Travaux dirigés (TD)
• Travaux pratiques (TP)
• Exercices corrigés supplémentaires
• QCM d'évaluation
• Résumé — les notions importantes
• Vidéos associées aux leçons
• Sources et références

Comment utiliser ce cours : lis chaque leçon dans l'ordre, refais les exemples à la main, tente chaque exercice AVANT de lire son corrigé, puis termine par le QCM pour vérifier ce que tu as retenu.

Introduction à la matière

En première année, tu as découvert les probabilités et les premiers indicateurs statistiques. Ce cours franchit l'étape suivante : il ne s'agit plus seulement de décrire les données que l'on a sous les yeux, mais de tirer des conclusions sur ce que l'on n'a pas mesuré. Combien d'étudiants faut-il interroger pour estimer une proportion à 5 % près ? Le lien observé entre les heures de révision et la note est-il fort ou illusoire ? L'écart entre une moyenne d'échantillon et la valeur annoncée par un fabricant est-il significatif ou dû au hasard de l'échantillonnage ? C'est le domaine de la statistique inférentielle, et il repose entièrement sur le socle descriptif que nous allons d'abord consolider.

La démarche du cours est volontairement progressive et entièrement calculée à la main sur de petits jeux de données inventés. Nous commençons par organiser et représenter une série (leçon 1), puis par la résumer par ses paramètres de position et de dispersion (leçon 2). La leçon 3 étudie le lien entre deux variables grâce à la régression linéaire et au coefficient de corrélation. La loi normale et l'échantillonnage (leçon 4) fournissent ensuite l'outil de probabilité qui rend possibles l'estimation par intervalle de confiance (leçon 5) et les tests d'hypothèses (leçon 6). Enfin, la leçon 7 montre comment refaire toutes ces analyses, plus vite et sur de gros volumes, avec un tableur et avec Python.

Un fil conducteur traverse tout le cours : chaque nombre annoncé doit pouvoir être retrouvé par le calcul, et chaque conclusion doit dire avec quel risque d'erreur elle est prise. En informatique, ces compétences servent partout : analyser des journaux

d'activité, comparer les temps de réponse de deux versions d'un programme, dimensionner un échantillon de test, ou alimenter un tableau de bord. Travaille chaque exemple au brouillon avant de lire la suite : en statistique, on ne comprend vraiment que ce que l'on a calculé soi-même au moins une fois.

Objectifs d'apprentissage

À la fin de ce cours, tu seras capable de :

- Organiser une série statistique en tableau d'effectifs, de fréquences et d'effectifs cumulés, et choisir la représentation graphique adaptée.
- Calculer et interpréter moyenne, médiane, quartiles, mode, étendue, variance et écart-type en précisant la convention utilisée (population ou échantillon).
- Construire la droite de régression par la méthode des moindres carrés et interpréter le coefficient de corrélation linéaire.
- Utiliser la loi normale et la variable centrée réduite pour calculer des probabilités sur une variable et sur une moyenne d'échantillon.
- Construire un intervalle de confiance pour une moyenne et pour une proportion, et déterminer la taille d'échantillon nécessaire pour une marge donnée.
- Mener un test d'hypothèses complet : hypothèses, seuil, statistique, p-value, décision, et distinguer les erreurs de première et de seconde espèce.
- Réaliser une analyse complète dans un tableur et en Python (module statistics et bibliothèque pandas) en contrôlant la cohérence des résultats.

Leçon 1 — Rappels : séries statistiques et représentations graphiques

Une étude statistique commence toujours par trois définitions. La population est l'ensemble complet que l'on veut décrire (par exemple les 2 400 étudiants de l'IAM) ; un individu est un élément de cette population ; un échantillon est un sous-ensemble d'individus effectivement observés. La variable (ou caractère) étudiée peut être qualitative (modalités non numériques : mode de transport, filière) ou quantitative (valeurs numériques : temps de trajet, note). Une variable quantitative est discrète si elle prend des valeurs isolées (nombre de frères et sœurs : 0, 1, 2, ...) et continue si elle peut prendre n'importe quelle valeur d'un intervalle (un temps, une taille, un poids).

Pour rendre une série lisible, on la range dans un tableau : pour chaque modalité ou chaque classe, l'effectif n_i compte les individus concernés, la fréquence $f_i = n_i/N$ donne la part correspondante (souvent en pourcentage), et les effectifs cumulés croissants additionnent les effectifs au fil des classes. Les fréquences cumulées répondent aux questions du type « quelle proportion d'étudiants met au plus 30 minutes ? ». Quand la variable est continue, on regroupe les valeurs en classes de même amplitude, en prenant garde à la convention des bornes : dans tout ce cours, une classe [a ; b[contient a mais pas b.

Le choix du graphique dépend du type de variable. Le diagramme en bâtons (ou en barres) convient aux variables qualitatives et aux variables discrètes : la hauteur de

chaque bâton est proportionnelle à l'effectif. Le diagramme circulaire (« camembert ») visualise des parts : l'angle de chaque secteur vaut fréquence × 360°. L'histogramme est réservé aux variables continues regroupées en classes : les rectangles sont collés les uns aux autres et, à amplitude égale, c'est leur hauteur qui est proportionnelle à l'effectif. Confondre histogramme et diagramme en bâtons est l'erreur classique : dans un histogramme, il n'y a pas d'espace entre les rectangles car l'axe est un axe numérique continu.

L'essentiel
Population, individu, échantillon ; variable qualitative ou quantitative (discrète/continue). Tableau = effectifs, fréquences (somme 1 ou 100 %), effectifs et fréquences cumulés. Graphique selon le type : bâtons (qualitatif/discret), circulaire (parts, angle = f × 360°), histogramme (continu en classes, rectangles jointifs).

Exemple — Temps de trajet domicile–IAM de 24 étudiants (variable continue, en classes)

```
Classe (min) Effectif Fréquence Cumulés F. cumulée Angle
[0 ; 15[ 3 12,50 % 3 12,50 % 45°
[15 ; 30[ 8 33,33 % 11 45,83 % 120°
[30 ; 45[ 7 29,17 % 18 75,00 % 105°
[45 ; 60[ 4 16,67 % 22 91,67 % 60°
[60 ; 75[ 2 8,33 % 24 100,00 % 30°
Total 24 100,00 %

Lecture : 45,83 % des étudiants mettent moins de 30 minutes ;
l'angle du secteur [15 ; 30[ vaut 8/24 × 360° = 120°.
Représentation adaptée : histogramme (variable continue en classes)
ou diagramme circulaire pour comparer les parts.
```

À retenir

- La somme des effectifs vaut N, celle des fréquences vaut 1 (ou 100 %) : deux contrôles gratuits de tout tableau.
- Les cumulés n'ont de sens que si les modalités sont ordonnées (jamais pour une variable qualitative nominale).
- Histogramme = variable continue en classes, rectangles collés ; bâtons = modalités séparées.

Exercice

On a demandé à ces mêmes 24 étudiants leur principal mode de transport pour venir à l'IAM : Marche 9, Moto 6, Bus (SOTOMA) 5, Voiture 4. 1) Calcule la fréquence (en %) de chaque modalité. 2) Calcule l'angle du secteur « Moto » dans un diagramme circulaire. 3) Peut-on calculer des effectifs cumulés pour cette variable ? Justifie. 4) Quel graphique est le mieux adapté ?

✔ Corrigé
1) Marche : 9/24 = 37,50 % ; Moto : 6/24 = 25,00 % ; Bus : 5/24 ≈ 20,83 % ; Voiture : 4/24 ≈ 16,67 %. Contrôle : 37,50 + 25,00 + 20,83 + 16,67 = 100,00 %. 2) Angle Moto = 0,25 × 360° = 90°. 3) Non : la variable « mode de transport » est qualitative nominale, ses modalités n'ont pas d'ordre naturel ; un cumul dépendrait de l'ordre arbitraire choisi et n'aurait aucune signification. 4) Un diagramme en barres (comparaison des modalités) ou un diagramme circulaire (vision des parts) ; un histogramme serait incorrect car la variable n'est pas numérique continue.

Leçon 2 — Paramètres de position et paramètres de dispersion

Les paramètres de position résument le « centre » d'une série. La moyenne arithmétique $\bar{x} = (x_1 + \ldots + x_N)/N$ utilise toutes les valeurs, ce qui la rend sensible aux valeurs extrêmes. La médiane Me partage la série triée en deux moitiés égales : la moitié des valeurs est en dessous, l'autre au-dessus ; elle résiste aux valeurs aberrantes. Les quartiles Q1 et Q3 prolongent l'idée : Q1 est la médiane de la première moitié de la série triée, Q3 celle de la seconde moitié, et l'intervalle [Q1 ; Q3] contient le cœur de la série (environ 50 % des valeurs). Le mode est la valeur la plus fréquente. Pour décrire correctement une série, on donne toujours au moins un paramètre de position ET un paramètre de dispersion.

La dispersion mesure l'étalement autour du centre. L'étendue (max − min) est simple mais ne dépend que des deux valeurs extrêmes. L'écart interquartile Q3 − Q1 décrit l'étalement de la moitié centrale. La grandeur de référence est la variance, moyenne des carrés des écarts à la moyenne : elle se calcule commodément par la formule développée variance = $(\Sigma x_i^2)/N - \bar{x}^2$. Son inconvénient : elle s'exprime dans l'unité au carré. On utilise donc surtout l'écart-type σ, racine carrée de la variance, qui a la même unité que les données. Le coefficient de variation CV = $\sigma/\bar{x}$ (en %) permet de comparer la dispersion de séries d'unités ou de niveaux différents.

Reste une convention à fixer une fois pour toutes dans ce cours. Quand la série décrit TOUTE la population étudiée, la variance se divise par N : c'est la variance dite « de population », notée σ^2. Quand la série est un échantillon destiné à estimer la variance d'une population plus vaste, on divise la somme des carrés des écarts par n − 1 : c'est la variance « d'échantillon », notée s^2, qui corrige le fait qu'un échantillon sous-estime en général la dispersion réelle (nous la retrouverons aux leçons 5 et 6). Python traduit exactement cette distinction : statistics.pstdev divise par N, statistics.stdev divise par n − 1. Annoncer un écart-type sans préciser la convention est une faute de rigueur.

L'essentiel
Position : moyenne (sensible aux extrêmes), médiane et quartiles (robustes), mode. Dispersion : étendue, écart interquartile, variance = moyenne des carrés des écarts = $(\Sigma x_i^2)/N - \bar{x}^2$, écart-type = racine de la variance, CV = $\sigma/\bar{x}$. Convention : ÷ N pour une population complète, ÷ (n − 1) pour un échantillon (s^2).

Exemple — Notes d'un TP d'informatique : 10 étudiants (série complète, donc ÷ N)

```
Notes : 8, 12, 15, 9, 14, 12, 17, 11, 13, 9
Série triée : 8, 9, 9, 11, 12, 12, 13, 14, 15, 17

Somme = 120 -> moyenne x¯ = 120/10 = 12
Médiane = (12 + 12)/2 = 12 Mode = 12 (deux occurrences)
Q1 = médiane de [8, 9, 9, 11, 12] = 9
Q3 = médiane de [12, 13, 14, 15, 17] = 14
Écart interquartile = 14 − 9 = 5 Étendue = 17 − 8 = 9

Écarts à la moyenne : −4, 0, 3, −3, 2, 0, 5, −1, 1, −3
Carrés des écarts : 16, 0, 9, 9, 4, 0, 25, 1, 1, 9 (somme = 74)
Variance (population) = 74/10 = 7,4
Écart-type σ = √7,4 ≈ 2,72 points
Coefficient de variation = 2,72/12 ≈ 22,7 %
```

À retenir

- Moyenne et médiane se complètent : si elles sont très différentes, la série est asymétrique ou contient des valeurs extrêmes.
- Variance et écart-type : toujours annoncer si l'on divise par N ou par n − 1.
- Le coefficient de variation, sans unité, est le seul paramètre qui permet de comparer deux dispersions de nature différente.

Exercice

On mesure la taille (en cm) de 8 étudiants : 165, 170, 172, 168, 175, 180, 169, 171. Calcule la moyenne, la médiane, l'étendue, la variance (population) et l'écart-type. La somme des carrés des écarts à la moyenne vaut 147,5 : sers-toi de ce contrôle pour valider ton calcul de variance.

✔ Corrigé
Somme = 1 370, donc moyenne = 1 370/8 = 171,25 cm. Série triée : 165, 168, 169, 170, 171, 172, 175, 180 ; médiane = (170 + 171)/2 = 170,5 cm. Étendue = 180 − 165 = 15 cm. Variance = 147,5/8 = 18,4375 ≈ 18,44 cm² (le contrôle donné dans l'énoncé est bien retrouvé en additionnant les carrés des écarts : 39,0625 + 1,5625 + 0,5625 + 10,5625 + 14,0625 + 76,5625 + 5,0625 + 0,0625 = 147,5). Écart-type σ = √18,4375 ≈ 4,29 cm. Interprétation : les tailles sont assez resserrées autour de 171 cm, avec un écart typique d'environ 4,3 cm.

Leçon 3 — Régression linéaire et corrélation

Quand on observe deux variables quantitatives sur les mêmes individus (heures de révision et note, budget publicitaire et ventes), on représente les couples $(x_i ; y_i)$ par un nuage de points. Si le nuage s'étire le long d'une droite, il est naturel de résumer le lien par une droite d'ajustement. La méthode des moindres carrés choisit, parmi toutes les droites possibles, celle qui minimise la somme des carrés des écarts verticaux entre les points et la droite : les gros écarts sont pénalisés, ce qui rend l'ajustement

stable. Cette droite passe toujours par le point moyen ($\bar{x}$; $\bar{y}$), le « centre de gravité » du nuage.

Pour une droite d'équation $\hat{y} = ax + b$, les coefficients se calculent à partir de cinq sommes : Σx, Σy, Σxy, Σx^2 (et Σy^2 pour la corrélation). La pente vaut $a = (n\Sigma xy - \Sigma x\Sigma y) / (n\Sigma x^2 - (\Sigma x)^2)$ et l'ordonnée à l'origine $b = \bar{y} - a\cdot\bar{x}$. La pente s'interprète concrètement : « quand x augmente d'une unité, y augmente en moyenne de a ». La droite sert ensuite à prévoir $\hat{y}$ pour une nouvelle valeur de x, en restant prudent : la prévision n'est raisonnable qu'à l'intérieur ou près de la plage des x observés (extrapoler loin des données est un pari risqué).

Le coefficient de corrélation linéaire r mesure la qualité et le sens de l'alignement : $r = (\Sigma xy - \Sigma x\Sigma y/n) / \sqrt{[(\Sigma x^2 - (\Sigma x)^2/n)(\Sigma y^2 - (\Sigma y)^2/n)]}$. Il est toujours compris entre −1 et +1. Proche de +1, le lien linéaire croissant est fort ; proche de −1, il est fort et décroissant ; proche de 0, il n'y a pas de lien LINÉAIRE (un lien en courbe peut exister sans être détecté par r). En pratique : $|r| \geq 0{,}9$ lien très fort, 0,7 à 0,9 fort, 0,5 à 0,7 modéré, en dessous faible. Avertissement capital : une forte corrélation ne prouve JAMAIS une causalité — les ventes de glaces et les noyades sont corrélées parce qu'une troisième variable, la chaleur, les fait augmenter ensemble. r^2, le coefficient de détermination, indique la part de la variance de y « expliquée » par le modèle linéaire.

L'essentiel
Nuage de points → droite des moindres carrés $\hat{y} = ax + b$ avec $a = (n\Sigma xy - \Sigma x\Sigma y)/(n\Sigma x^2 - (\Sigma x)^2)$, $b = \bar{y} - a\cdot\bar{x}$; elle passe par ($\bar{x}$; $\bar{y}$). $r \in [-1 ; 1]$ mesure la force du lien linéaire ; r^2 = part de variance expliquée. Corrélation n'est pas causalité.

Exemple — Heures de révision (x) et note obtenue (y) pour 6 étudiants

```
x | y | xy | x² | y²
----+-----+------+------+------
2 | 8 | 16 | 4 | 64
4 | 11 | 44 | 16 | 121
5 | 13 | 65 | 25 | 169
7 | 14 | 98 | 49 | 196
8 | 16 | 128 | 64 | 256
10 | 18 | 180 | 100 | 324
Σx=36 Σy=80 Σxy=531 Σx²=258 Σy²=1130 (n = 6)

x¯ = 36/6 = 6 ȳ = 80/6 ≈ 13,33
a = (6×531 − 36×80)/(6×258 − 36²) = (3186 − 2880)/(1548 − 1296)
= 306/252 ≈ 1,21
b = 13,33 − 1,21×6 ≈ 6,05
Droite : ŷ = 1,21x + 6,05
r = 51/√(42 × 63,33) ≈ 0,99 -> lien linéaire très fort
Prévision pour 6 h de révision : ŷ = 6,05 + 1,21×6 ≈ 13,3
```

À retenir

- Construis toujours le tableau des sommes (Σx, Σy, Σxy, Σx^2, Σy^2) avant d'appliquer les formules : c'est là que naissent les erreurs.

• La pente a a une unité (celle de y par unité de x) et une interprétation concrète ; b n'en a pas toujours.

• r proche de 0 ne signifie pas « aucun lien », mais « aucun lien linéaire » ; et un r élevé ne prouve pas une cause.

Exercice

Une boutique en ligne suit, sur 5 mois, son budget publicitaire x (en milliers de FCFA) et ses ventes y (en milliers de FCFA) : (1 ; 12), (2 ; 15), (3 ; 17), (4 ; 20), (5 ; 22). On donne $\Sigma x = 15$, $\Sigma y = 86$, $\Sigma xy = 283$, $\Sigma x^2 = 55$, $\Sigma y^2 = 1\,542$. Détermine l'équation de la droite de régression de y en x, calcule le coefficient de corrélation r (arrondi à 3 décimales), interprète-le, puis prévois les ventes pour un budget de 6 000 FCFA.

✔ Corrigé

$a = (5\times283 - 15\times86)/(5\times55 - 15^2) = (1\,415 - 1\,290)/(275 - 225) = 125/50 = 2{,}5$. $\bar{x} = 3$ et $\bar{y} = 17{,}2$, donc $b = 17{,}2 - 2{,}5\times3 = 9{,}7$. Droite : $\hat{y} = 2{,}5x + 9{,}7$. Pour r : numérateur $= 283 - 15\times86/5 = 283 - 258 = 25$; dénominateur $= \sqrt{[(55 - 45)(1\,542 - 86^2/5)]} = \sqrt{[10 \times 62{,}8]} = \sqrt{628} \approx 25{,}06$; $r = 25/25{,}06 \approx 0{,}998$. Le lien linéaire est quasi parfait sur ces 5 mois : chaque millier de FCFA de publicité supplémentaire est associé à environ 2 500 FCFA de ventes en plus — sans que cela prouve que la publicité est la seule cause (saison, bouche-à-oreille…). Prévision pour $x = 6$: $\hat{y} = 9{,}7 + 2{,}5\times6 = 24{,}7$, soit environ 24 700 FCFA de ventes, en restant conscient qu'on extrapole légèrement au-delà des budgets observés (1 à 5).

Leçon 4 — La loi normale et l'échantillonnage

De nombreuses grandeurs mesurées sur de grands effectifs (tailles, notes d'un grand examen, erreurs de mesure, masses de produits fabriqués) se répartissent selon une courbe en cloche symétrique : la loi normale, entièrement déterminée par sa moyenne μ et son écart-type σ, notée $N(\mu ; \sigma)$. La probabilité qu'une variable X tombe dans un intervalle est l'aire sous la courbe au-dessus de cet intervalle ; l'aire totale vaut 1. La règle des 68–95–99,7 donne des repères immédiats : environ 68 % des valeurs sont dans $[\mu - \sigma ; \mu + \sigma]$, 95 % dans $[\mu - 2\sigma ; \mu + 2\sigma]$ et 99,7 % dans $[\mu - 3\sigma ; \mu + 3\sigma]$.

Pour calculer précisément, on ramène toute loi normale à la loi normale centrée réduite $N(0 ; 1)$ par le changement de variable $z = (x - \mu)/\sigma$: z compte le nombre d'écarts-types entre x et la moyenne. On lit alors dans la table (ou l'on calcule) $\Phi(z) = P(Z \le z)$, probabilité cumulée à gauche. Les symétries font le reste : $P(Z \ge z) = 1 - \Phi(z)$, $P(Z \le -z) = 1 - \Phi(z)$, et $P(a \le X \le b) = \Phi(z_b) - \Phi(z_a)$. Valeurs à connaître : $\Phi(1) \approx 0{,}8413$, $\Phi(1{,}5) \approx 0{,}9332$, $\Phi(1{,}96) \approx 0{,}9750$, $\Phi(2) \approx 0{,}9772$. En Python, $\Phi(z)$ s'obtient par $0{,}5\times(1 + \mathrm{erf}(z/\sqrt{2}))$ du module math.

L'échantillonnage applique ces idées à la moyenne d'un échantillon. Si l'on répète le tirage d'échantillons de taille n dans une population de moyenne μ et d'écart-type σ, les moyennes d'échantillon $\bar{x}$ se distribuent approximativement selon une loi normale de moyenne μ et d'écart-type $\sigma/\sqrt{n}$, appelé erreur-type de la moyenne. Deux faits essentiels : $\bar{x}$ est centrée sur la vraie moyenne (l'échantillonnage ne biaise pas en moyenne), et son écart-type diminue comme $1/\sqrt{n}$ — pour diviser l'incertitude par 2, il faut multiplier la taille de l'échantillon par 4. Pour de grands échantillons ($n \ge 30$ en

pratique), l'approximation normale des moyennes vaut même si la population de départ n'est pas normale : c'est le théorème central limite, le pilier des leçons 5 et 6.

L'essentiel
Loi normale N(μ ; σ) : cloche symétrique, aires = probabilités, règle 68–95–99,7. Centrer-réduire : z = (x − μ)/σ, lecture de Φ(z) = P(Z ≤ z). Moyenne d'échantillon : loi ≈ N(μ ; σ/√n) ; l'erreur-type σ/√n diminue en 1/√n.

Exemple — Tailles d'une grande population d'étudiants : X suit N(170 ; 10) (en cm)

```
1) P(X < 185) : z = (185 − 170)/10 = 1,5
P = Φ(1,5) ≈ 0,9332 -> 93,32 % des étudiants mesurent moins de 1,85 m

2) P(160 < X < 185) : z(160) = −1 et z(185) = 1,5
P = Φ(1,5) − Φ(−1) = 0,9332 − 0,1587 ≈ 0,7745 -> 77,45 %

3) P(X > 190) : z = (190 − 170)/10 = 2
P = 1 − Φ(2) = 1 − 0,9772 ≈ 0,0228 -> 2,28 % mesurent plus de 1,90 m

4) Échantillonnage : sur des échantillons de n = 25 étudiants,
la moyenne x¯ suit ≈ N(170 ; 10/√25) = N(170 ; 2)
P(x¯ > 174) : z = (174 − 170)/2 = 2 -> P ≈ 0,0228
P(168 < x¯ < 172) : z = ±1 -> P ≈ 0,6827 (la règle des 68 %)
```

À retenir

- Toujours centrer-réduire avant de lire la table : la table ne connaît que N(0 ; 1).
- Φ(z) donne une probabilité CUMULÉE à gauche ; un intervalle se calcule par une différence de deux Φ.
- L'erreur-type σ/√n gouverne toute l'inférence : elle relie la précision d'un échantillon à sa taille.

Exercice

La masse d'un sac de riz produit par une minoterie suit la loi normale N(50 ; 2) (en kg). 1) Calcule la probabilité qu'un sac pèse moins de 47 kg. 2) Calcule la probabilité qu'un sac pèse entre 48 kg et 52 kg. 3) Le commerçant qui reçoit un sac de 47 kg peut-il s'étonner ? Justifie avec le résultat de la question 1.

✔ Corrigé
1) z = (47 − 50)/2 = −1,5 ; P(X < 47) = Φ(−1,5) = 1 − Φ(1,5) = 1 − 0,9332 ≈ 0,0668, soit environ 6,68 % des sacs. 2) z(48) = −1 et z(52) = +1 ; P = Φ(1) − Φ(−1) = 0,8413 − 0,1587 ≈ 0,6827, soit 68,27 % des sacs — c'est exactement l'intervalle [μ − σ ; μ + σ] de la règle des 68 %. 3) Non : un sac de 47 kg se situe à 1,5 écart-type sous la moyenne, événement qui concerne près de 7 sacs sur 100 ; c'est inhabituel mais pas anormal. Une valeur à plus de 3 écarts-types (moins de 44 kg) serait, elle, suspecte (probabilité ≈ 0,13 %).

Leçon 5 — Estimation et intervalles de confiance

Estimer, c'est proposer une valeur pour un paramètre inconnu d'une population (sa moyenne μ, une proportion p) à partir d'un échantillon. L'estimation ponctuelle donne un seul nombre ($\bar{x}$ pour μ, la fréquence observée f pour p) : simple, mais sans aucune indication de précision. L'estimation par intervalle corrige ce défaut : elle fournit un intervalle construit de telle sorte que la méthode employée « capture » la vraie valeur dans une proportion annoncée des cas — 95 % en général. C'est cette proportion que l'on appelle le niveau de confiance ; elle porte sur la PROCÉDURE, pas sur l'intervalle déjà calculé : dire « μ est dans [11,42 ; 13,38] avec 95 % de confiance » signifie que la méthode réussit 95 fois sur 100, et que nous acceptons le risque de faire partie des 5 échecs.

Pour une moyenne, l'intervalle au niveau 95 % est $\bar{x} \pm 1{,}96 \times \sigma/\sqrt{n}$ lorsque σ est connu (ou l'échantillon grand). La quantité $1{,}96 \times \sigma/\sqrt{n}$ est la marge d'erreur : elle diminue quand n augmente (en $1/\sqrt{n}$) et augmente avec la dispersion σ. Quand σ est inconnu, on le remplace par l'écart-type d'échantillon s (division par $n - 1$) et, pour les petits échantillons, on remplace 1,96 par un coefficient de Student t, plus grand, qui tient compte de l'incertitude supplémentaire (par exemple $t = 2{,}262$ pour 9 degrés de liberté). Pour une proportion, l'intervalle est $f \pm 1{,}96 \times \sqrt{f(1 - f)/n}$, valable pour de grands échantillons (en pratique $n \cdot f$ et $n(1 - f)$ au moins égaux à 5).

L'intervalle sert aussi à DIMENSIONNER une enquête avant de la lancer. Pour estimer une proportion avec une marge E au niveau 95 %, il faut $n \geq 1{,}96^2 \times p(1 - p)/E^2$; comme p est inconnu, on prend le cas le plus défavorable $p = 0{,}5$, ce qui donne $n \geq 0{,}9604/E^2$. Pour une marge de 5 %, $n = 385$: c'est l'ordre de grandeur des sondages sérieux. Accepter une marge de 10 % divise le coût par 4 ($n = 97$), mais livre une estimation quatre fois moins précise en amplitude. Toute la crédibilité d'une enquête tient dans ce trio : taille n, marge, niveau de confiance — un résultat annoncé sans sa marge ne vaut rien.

L'essentiel
Intervalle de confiance : procédure qui capture la vraie valeur dans (niveau) % des cas. Moyenne : $\bar{x} \pm 1{,}96\ \sigma/\sqrt{n}$ (s et coefficient de Student si σ inconnu/petit n). Proportion : $f \pm 1{,}96\sqrt{f(1-f)/n}$. Taille requise pour une marge E : $n \geq 1{,}96^2 \cdot p(1-p)/E^2$, pire cas $p = 0{,}5$.

Exemple — Deux estimations au niveau de confiance 95 %

```
A) Moyenne d'un contrôle (σ connu = 3) : n = 36, x̄ = 12,4
Marge = 1,96 × 3/√36 = 1,96 × 0,5 = 0,98
IC : 12,4 ± 0,98 -> [11,42 ; 13,38]

B) Proportion d'étudiants révisant sur smartphone :
130 étudiants sur 200 interrogés -> f = 0,65
Erreur-type = √(0,65 × 0,35/200) ≈ 0,0337
Marge = 1,96 × 0,0337 ≈ 0,066
IC : 0,65 ± 0,066 -> [0,584 ; 0,716], soit [58,4 % ; 71,6 %]

C) Taille d'échantillon pour une marge de 5 % (p inconnu) :
n ≥ 1,96² × 0,5 × 0,5/0,05² = 384,16 -> 385 personnes
```

À retenir

- Un intervalle de confiance sans son niveau (90 %, 95 %, 99 %) est incomplet ; 95 % est le standard.
- La marge diminue en 1/√n : la quadrupler exige 16 fois plus d'observations — la précision se paie cher.
- Pour une proportion, le pire cas p = 0,5 donne la taille d'échantillon prudente, valable quelle que soit la vraie valeur.

Exercice

Une coopérative étudiante relève le montant du panier moyen dans sa boutique : sur n = 49 achats, la moyenne est de 5 200 FCFA et l'écart-type d'échantillon s vaut 280 FCFA. Construis l'intervalle de confiance à 95 % pour le montant moyen réel du panier (grand échantillon : utilise 1,96 et s). Interprète le résultat en une phrase correcte.

✔ Corrigé
Marge = 1,96 × s/√n = 1,96 × 280/7 = 1,96 × 40 = 78,4 FCFA. IC : 5 200 ± 78,4, soit [5 121,60 ; 5 278,40] FCFA. Interprétation correcte : « La méthode utilisée produit un intervalle qui contient le vrai montant moyen dans 95 % des applications ; pour cet échantillon, l'intervalle obtenu va d'environ 5 122 à 5 278 FCFA. » Il faut éviter la formulation « il y a 95 % de chances que la moyenne soit dans cet intervalle » : la vraie moyenne est fixe, c'est l'intervalle qui varie d'un échantillon à l'autre.

Leçon 6 — Tests d'hypothèses : initiation

Un test d'hypothèses tranche entre deux affirmations sur un paramètre, à partir d'un échantillon et avec un risque d'erreur contrôlé. On formule l'hypothèse nulle H_0 (le statu quo : valeur annoncée, absence d'effet, égalité) et l'hypothèse alternative H_1 (la nouveauté : valeur différente, supérieure ou inférieure). Le test est bilatéral si H_1 dit « ≠ » (on surveille les deux côtés) et unilatéral si H_1 dit « > » ou « < » (un seul côté nous intéresse — le choix doit être fait AVANT de regarder les données). On fixe ensuite le seuil de signification α, le risque accepté de rejeter H_0 à tort ; α = 5 % est l'usage le plus courant.

Le déroulement est toujours le même. On calcule une statistique de test qui mesure l'écart entre l'échantillon et H_0, exprimé en erreurs-types : pour une moyenne avec σ

connu, $z = (\bar{x} - \mu_0)/(\sigma/\sqrt{n})$. Puis on décide, de deux façons équivalentes : soit l'on compare $|z|$ à la valeur critique (1,96 en bilatéral à 5 % ; 1,645 en unilatéral), soit l'on calcule la p-value, probabilité — si H_0 était vraie — d'obtenir un résultat au moins aussi éloigné de H_0 que celui observé ; on rejette H_0 si p-value $\leq \alpha$. Si l'on ne rejette pas, on conclut prudemment « les données sont compatibles avec H_0 », jamais « H_0 est prouvée » : un petit échantillon peut simplement manquer de puissance pour détecter un écart réel.

Deux erreurs symétriques menacent la décision. L'erreur de première espèce (risque α, choisi par nous) consiste à rejeter H_0 alors qu'elle est vraie — fausse alerte. L'erreur de seconde espèce (risque β) consiste à ne pas rejeter H_0 alors qu'elle est fausse — détection manquée ; la puissance du test, $1 - \beta$, croît avec la taille de l'échantillon et avec l'ampleur de l'écart réel. Diminuer α sans augmenter n augmente mécaniquement β : on ne peut pas réduire les deux risques à la fois à taille fixée. C'est exactement le dilemme d'un détecteur de fumée : trop sensible, il sonne pour une tartine grillée (type I) ; pas assez, il laisse passer un début d'incendie (type II). Un compte rendu de test complet donne toujours : hypothèses, seuil, statistique, p-value, décision, et interprétation dans le contexte.

L'essentiel
H_0 (statu quo) contre H_1 (bilatérale $\neq$ ou unilatérale $<$, $>$), seuil α fixé à l'avance. Statistique $z = (\bar{x} - \mu_0)/(\sigma/\sqrt{n})$; décision par valeur critique ou par p-value $\leq \alpha$. Erreur de type I : rejeter un H_0 vrai (risque α) ; type II : manquer un H_0 faux (risque β) ; la puissance croît avec n.

Exemple — Test bilatéral : la durée de vie annoncée d'une ampoule (α = 5 %)

```
Annonce du fabricant : durée moyenne μ = 1 000 h
Échantillon : n = 25 ampoules, x¯ = 965 h, σ connu = 100 h

H0 : μ = 1 000 H1 : μ ≠ 1 000 (test bilatéral)
Statistique : z = (965 − 1 000)/(100/√25) = −35/20 = −1,75
Valeur critique à 5 % : ±1,96
|z| = 1,75 < 1,96 -> on NE rejette PAS H0
p-value = 2 × P(Z < −1,75) = 2 × 0,0401 ≈ 0,0801 > 0,05
(même décision, comme attendu)

Conclusion : l'écart observé (−35 h) est compatible avec la
simple variabilité d'échantillonnage. Cela ne PROUVE pas que
μ = 1 000 h : un écart réel modéré resterait possible.
```

À retenir

- La p-value n'est pas « la probabilité que H_0 soit vraie » : c'est la probabilité des données (ou plus extrêmes) SI H_0 est vraie.
- « Ne pas rejeter H_0 » ≠ « H_0 est vraie » : sans puissance suffisante, le test peut ne rien voir.
- Le caractère unilatéral ou bilatéral se décide avant l'analyse, sinon le seuil annoncé est mensonger.

Exercice

Une machine remplit des bouteilles censées contenir 500 mL. Un contrôle porte sur n = 16 bouteilles : moyenne mesurée 495 mL, écart-type (connu, issu de l'historique de la machine) σ = 8 mL. On soupçonne un sous-remplissage. Formule les hypothèses adaptées, effectue le test au seuil de 5 % (valeur critique unilatérale : 1,645), calcule la p-value, et conclus pour l'atelier de production.

✔ Corrigé

Le soupçon porte sur un seul côté : H_0 : $\mu = 500$ contre H_1 : $\mu < 500$ (test unilatéral à gauche), seuil $\alpha = 5$ %. Statistique : $z = (495 - 500)/(8/\sqrt{16}) = -5/2 = -2{,}5$. Décision : $z = -2{,}5 < -1{,}645$, donc on rejette H_0. p-value = $P(Z < -2{,}5) \approx 0{,}0062$, très inférieure à 0,05 : même conclusion. Interprétation : si la machine était correctement réglée, un échantillon aussi bas (ou plus bas) ne surviendrait que dans environ 0,6 % des contrôles ; l'hypothèse du hasard seul est peu crédible, l'atelier doit vérifier le réglage de la machine. Le risque de cette décision est l'erreur de première espèce, borné par $\alpha = 5$ %.

Leçon 7 — Analyse de données avec le tableur et avec Python

Le tableur (Excel, LibreOffice Calc) est l'outil d'analyse le plus répandu dans les entreprises : données en colonnes, une observation par ligne, et des fonctions statistiques intégrées. En français : MOYENNE(plage) pour la moyenne, MEDIANE pour la médiane, ECARTYPEP (population, ÷ N) et ECARTYPE (échantillon, ÷ n − 1) sous LibreOffice — ÉCARTYPE.PEARSON et ÉCARTYPE.STANDARD sous Excel — pour l'écart-type, PENTE(y ; x) et ORDONNEE.ORIGINE(y ; x) pour la droite de régression, COEFFICIENT.CORRELATION(y ; x) pour r. L'assistant graphique produit bâtons, histogrammes et nuages de points avec droite de tendance. Forces du tableur : immédiat, visuel, sans code. Limites : manipulations manuelles difficiles à reproduire, erreurs de plage silencieuses, et pénible au-delà de quelques milliers de lignes.

Python prend le relais dès que l'analyse doit être répétée, documentée ou volumineuse. Le module statistics de la bibliothèque standard suffit pour les séries simples : mean, median, pstdev (÷ N), stdev (÷ n − 1) — on y retrouve exactement les conventions de la leçon 2. La bibliothèque pandas manipule des tableaux (DataFrame) proches d'une feuille de tableur, mais par programme : read_csv charge un fichier, head() inspecte les premières lignes, describe() produit en un appel effectif, moyenne, écart-type (d'échantillon par défaut), minimum, quartiles et maximum de chaque colonne numérique, et corr calcule des corrélations. Attention, piège célèbre : pandas affiche par défaut l'écart-type d'échantillon (ddof=1) ; pour l'écart-type de population, préciser std(ddof=0).

Quel que soit l'outil, la méthode professionnelle reste identique : 1) inspecter les données (dimensions, types, valeurs manquantes, valeurs aberrantes) avant tout calcul ; 2) décrire (indicateurs + graphiques) ; 3) modéliser ou tester ; 4) vérifier la cohérence entre au moins deux calculs indépendants (par exemple le même écart-type dans le tableur et en Python, en ayant aligné les conventions ÷ N / ÷ (n −

1)) ; 5) consigner la démarche pour qu'un collègue puisse la reproduire. Un script Python versionné bat, sur ce point, n'importe quel classeur cliqué à la main : il EST la documentation de l'analyse.

L'essentiel
Tableur : MOYENNE, MEDIANE, ECARTYPEP/ECARTYPE, PENTE, ORDONNEE.ORIGINE, COEFFICIENT.CORRELATION, graphiques intégrés. Python : statistics (mean, median, pstdev/stdev) et pandas (read_csv, describe, corr). Point de vigilance commun : aligner la convention d'écart-type (÷ N ou ÷ (n − 1)) entre les outils avant de comparer.

Exemple — Ventes mensuelles d'une boutique (milliers de FCFA) : le même calcul, deux outils

```
Données : Janv 120, Févr 135, Mars 128, Avr 150, Mai 142, Juin 160

TABLEUR (ventes en B2:B7, numéros de mois en A2:A7) :
Moyenne =MOYENNE(B2:B7) -> 139,17
Médiane =MEDIANE(B2:B7) -> 138,5
Éc.-type =ECARTYPE(B2:B7) -> 14,62 (échantillon)
Corrélation mois/ventes -> 0,89

PYTHON :
import pandas as pd
df = pd.DataFrame({"mois": ["Janv", "Févr", "Mars",
"Avr", "Mai", "Juin"],
"ventes": [120, 135, 128, 150, 142, 160]})
print(df["ventes"].mean()) # 139,17
print(df["ventes"].median()) # 138,5
print(df["ventes"].std()) # 14,62 (ddof=1 par défaut)
print(df["ventes"].std(ddof=0)) # 13,35 (population)
print(df["ventes"].describe()) # min 120, max 160, quartiles…

Interprétation : ventes en croissance (corrélation 0,89 avec le
temps), niveau typique ≈ 139 000 FCFA, dispersion modérée.
```

À retenir

- Avant de calculer : inspecter (types, manquants, aberrants) — un résultat propre sur des données sales reste faux.
- pandas et le tableur doivent raconter la même histoire ; tout écart vient presque toujours de la convention d'écart-type.
- Le script est la documentation reproductible de l'analyse ; le classeur seul ne dit pas comment il a été produit.

Exercice

Avec le module statistics de Python, on saisit les notes de la leçon 2 : notes = [8, 12, 15, 9, 14, 12, 17, 11, 13, 9]. Écris les instructions qui affichent la moyenne, la médiane, l'écart-type de population et l'écart-type d'échantillon, et donne les valeurs affichées. Explique en une phrase pourquoi les deux écarts-types diffèrent.

✔ Corrigé
import statistics as st ; print(st.mean(notes)) affiche 12 ; print(st.median(notes)) affiche 12.0 ; print(st.pstdev(notes)) affiche environ 2.72 ; print(st.stdev(notes)) affiche environ 2.87. Les deux écarts-types partent de la même somme des carrés des écarts (74) mais la divisent différemment : par N = 10 pour la population (variance 7,4), par n − 1 = 9 pour l'échantillon (variance ≈ 8,22) — d'où un écart-type d'échantillon légèrement plus grand, qui compense la sous-estimation systématique de la dispersion quand on ne connaît qu'un échantillon.

Travaux dirigés (TD)

TD 1 — Analyse complète d'une série de notes (descriptif)

Voici les notes (sur 20) obtenues par 12 étudiants à un contrôle de statistiques : 7, 9, 10, 11, 12, 12, 13, 14, 15, 16, 17, 18. 1) Calcule la moyenne, la médiane, le mode et l'étendue. 2) Détermine Q1 et Q3 par la méthode des moitiés, puis l'écart interquartile. 3) Calcule la variance (population) et l'écart-type, sachant que la somme des carrés des écarts à la moyenne vaut environ 121,67 — retrouve ce contrôle par le calcul de Σx^2. 4) Regroupe les notes en classes [0 ; 10[, [10 ; 12[, [12 ; 14[, [14 ; 16[, [16 ; 20] et donne les effectifs ; quel graphique convient ? 5) Rédige en deux phrases le portrait de cette classe.

✔ Corrigé du TD 1
1) Somme = 154, moyenne = 154/12 ≈ 12,83. Série triée (déjà en ordre) : médiane = (12 + 13)/2 = 12,5. Mode = 12 (deux occurrences, toutes les autres valeurs sont uniques). Étendue = 18 − 7 = 11. 2) Moitié basse [7, 9, 10, 11, 12, 12] : Q1 = (10 + 11)/2 = 10,5. Moitié haute [13, 14, 15, 16, 17, 18] : Q3 = (15 + 16)/2 = 15,5. Écart interquartile = 5 : la moitié centrale des étudiants se situe entre 10,5 et 15,5. 3) Σx^2 = 49 + 81 + 100 + 121 + 144 + 144 + 169 + 196 + 225 + 256 + 289 + 324 = 2 098. Variance = $\Sigma x^2/N - \bar{x}^2$ = 2 098/12 − (12,833)² ≈ 174,83 − 164,69 ≈ 10,14 ; contrôle : 10,14 × 12 ≈ 121,67 ✓. Écart-type σ = √10,14 ≈ 3,18 points. 4) Effectifs : [0 ; 10[: 2 (7, 9) ; [10 ; 12[: 2 (10, 11) ; [12 ; 14[: 3 (12, 12, 13) ; [14 ; 16[: 2 (14, 15) ; [16 ; 20] : 3 (16, 17, 18). Total : 12 ✓. Graphique : histogramme (variable quantitative regroupée en classes). Attention, les classes n'ont pas toutes la même amplitude (la dernière vaut 4, les autres 2) : à amplitude inégale, c'est la SURFACE des rectangles qui doit être proportionnelle à l'effectif, donc la hauteur de la dernière classe doit être divisée par 2 à effectif égal. 5) Portrait : « Classe plutôt homogène et d'un niveau correct : moyenne 12,8, médiane 12,5 et écart-type d'environ 3,2 points ; la moitié des étudiants se situe entre 10,5 et 15,5, avec deux étudiants en difficulté sous la moyenne de 10 et un petit groupe d'excellents résultats entre 16 et 18. »

TD 2 — Enquête sur l'usage d'Internet mobile : estimation et test

Une association étudiante affirme que « plus de 60 % des étudiants de l'IAM utilisent Internet mobile tous les jours ». Pour vérifier, elle interroge un échantillon aléatoire de 400 étudiants : 268 déclarent un usage quotidien. 1) Calcule la fréquence observée f.

2) Construis l'intervalle de confiance à 95 % pour la vraie proportion p. 3) Teste, au seuil de 5 %, l'hypothèse H_0 : p = 0,60 contre H_1 : p > 0,60 (sous H_0, l'erreur-type vaut √(0,60 × 0,40/400) ≈ 0,0245 ; valeur critique unilatérale : 1,645). 4) L'affirmation de l'association est-elle étayée ? Rédige la conclusion en langage clair, en précisant le risque pris.

✔ Corrigé du TD 2
1) f = 268/400 = 0,67. 2) Erreur-type estimée = √(0,67 × 0,33/400) ≈ 0,0235 ; marge = 1,96 × 0,0235 ≈ 0,046. IC à 95 % : [0,624 ; 0,716], soit entre environ 62,4 % et 71,6 % d'utilisateurs quotidiens. 3) Statistique : z = (0,67 − 0,60)/0,0245 ≈ 2,86. Comme 2,86 > 1,645, on rejette H_0 au seuil de 5 %. La p-value vaut P(Z > 2,86) ≈ 0,0021 : si la vraie proportion était 60 %, un échantillon aussi favorable (ou davantage) n'apparaîtrait que dans environ 0,2 % des sondages. 4) Conclusion : l'enquête étaye l'affirmation de l'association — la proportion réelle dépasse vraisemblablement 60 %, et l'intervalle de confiance suggère plutôt une valeur autour de 62 à 72 %. La décision de rejeter H_0 comporte un risque d'erreur de première espèce au plus égal au seuil choisi, 5 % (en réalité, la p-value de 0,0021 montre que les données sont nettement au-delà du seuil).

Travaux pratiques (TP)

TP 1 — Mini-étude statistique complète, du tableur à Python

Une enseignante veut savoir si le temps de révision influence la note de son module. Elle relève, pour 10 étudiants volontaires, les heures de révision de la semaine précédente (x) et la note obtenue (y) : (3 ; 10), (4 ; 11), (5 ; 12), (2 ; 9), (6 ; 13), (7 ; 15), (8 ; 14), (5 ; 13), (9 ; 16), (4 ; 10). Travail demandé : 1) Saisis les données dans un tableur, construis le nuage de points et fais calculer moyenne, médiane et écart-type (échantillon) de chaque variable. 2) Détermine à la main, par le tableau des sommes, l'équation de la droite de régression de y en x et le coefficient de corrélation r ; vérifie avec les fonctions PENTE, ORDONNEE.ORIGINE et COEFFICIENT.CORRELATION du tableur. 3) Refais l'analyse en Python (statistics puis pandas) et compare chaque valeur. 4) Prévois la note d'un étudiant ayant révisé 6,5 heures et discute la fiabilité de cette prévision. 5) Construis l'intervalle de confiance à 95 % pour la note moyenne de la classe entière à partir de cet échantillon (petit échantillon : coefficient de Student t = 2,262 pour 9 degrés de liberté, avec s l'écart-type d'échantillon des notes). 6) Rédige un compte rendu de 5 lignes : ce que l'étude suggère, et ses limites.

✔ Attendus du TP 1
1) Tableur : heures — moyenne 5,3 h, écart-type (population) 2,10 h ; notes — moyenne 12,3, médiane 12,5, écart-type d'échantillon s ≈ 2,31 (écart-type de population ≈ 2,19). Le nuage de points monte nettement vers la droite : un ajustement linéaire est pertinent. 2) Sommes : $\Sigma x = 53$, $\Sigma y = 123$, $\Sigma xy = 696$, $\Sigma x^2 = 325$, $\Sigma y^2 = 1\,561$ ($n = 10$). Pente : $a = (10 \times 696 - 53 \times 123)/(10 \times 325 - 53^2) = (6\,960 - 6\,519)/(3\,250 - 2\,809) = 441/441 = 1{,}0$. Ordonnée : $b = 12{,}3 - 1{,}0 \times 5{,}3 = 7{,}0$. Droite : $\hat{y} = x + 7$. Corrélation : numérateur $= 696 - 53 \times 123/10 = 44{,}1$; dénominateur $= \sqrt{[(325 - 280{,}9) \times (1\,561 - 1\,512{,}9)]} = \sqrt{(44{,}1 \times 48{,}1)} \approx 46{,}06$; $r \approx 0{,}96$. Les fonctions du tableur redonnent exactement $a = 1$, $b = 7$ et $r \approx 0{,}957$. 3) Python : statistics.mean([notes]) = 12.3, pstdev ≈ 2.19, stdev ≈ 2.31 ; pandas describe() retrouve les mêmes valeurs (écart-type d'échantillon par défaut). 4) Pour 6,5 h : $\hat{y} = 6{,}5 + 7 = 13{,}5$. Prévision raisonnable : 6,5 h est à l'intérieur de la plage observée (2 à 9 h) et r est très élevé ; elle reste une moyenne attendue, pas une promesse — la dispersion autour de la droite vaut environ 2 points. 5) IC : marge $= 2{,}262 \times 2{,}31/\sqrt{10} \approx 1{,}65$; IC à 95 % : $12{,}3 \pm 1{,}65$, soit [10,65 ; 13,95]. 6) Compte rendu attendu (esprit) : lien fort entre révision et note sur cet échantillon ($r \approx 0{,}96$, pente d'environ 1 point par heure) ; mais échantillon petit (10 volontaires, donc possiblement biaisé), corrélation n'est pas causalité (la motivation peut expliquer les deux), et l'intervalle de confiance de la moyenne reste large. Étude à confirmer sur la classe entière.

Exercices corrigés supplémentaires

Exercice 1

On considère la série de 5 valeurs : 4, 8, 6, 10, 12. 1) Calcule la moyenne, la médiane, la variance (population) et l'écart-type. 2) On ajoute une sixième valeur : 20. Recalcule la moyenne et la médiane, puis l'écart-type. 3) Commente l'effet de cette valeur extrême sur chaque paramètre.

✔ Corrigé
1) Somme = 40, moyenne = 8. Série triée : 4, 6, 8, 10, 12 ; médiane = 8. Écarts à la moyenne : −4, 0, −2, 2, 4 ; carrés : 16, 0, 4, 4, 16 (somme 40) ; variance = 40/5 = 8 ; écart-type $= \sqrt{8} \approx 2{,}83$. 2) Nouvelle somme = 60, moyenne = 10. Série triée : 4, 6, 8, 10, 12, 20 ; médiane = (8 + 10)/2 = 9. Nouvelle somme des carrés des écarts : 160, d'où variance = 160/6 ≈ 26,67 et écart-type ≈ 5,16. 3) Commentaire : la moyenne grimpe de 8 à 10 (+25 %) et l'écart-type presque double (2,83 → 5,16), alors que la médiane ne bouge que de 8 à 9. C'est l'illustration standard de la robustesse de la médiane : une seule valeur extrême déplace fortement la moyenne et la dispersion, très peu la médiane. Pour une série contenant des valeurs aberrantes, on présente la médiane accompagnée de l'écart interquartile.

Exercice 2

Les scores d'un test d'aptitude passé par un grand nombre de candidats suivent approximativement la loi normale N(60 ; 12). 1) Quelle proportion de candidats obtient plus de 84 ? 2) Quelle proportion obtient entre 48 et 72 ? 3) Sur 500 candidats, combien environ dépassent 84 ? 4) Un candidat admis doit être dans les 16 %

meilleurs environ ; à partir de quel score se situe-t-on, sachant que Φ(1) ≈ 0,8413 ?

✔ Corrigé
1) z = (84 − 60)/12 = 2 ; P(X > 84) = 1 − Φ(2) = 1 − 0,9772 ≈ 0,0228, soit environ 2,28 % des candidats. 2) 48 et 72 correspondent à μ − σ et μ + σ : P ≈ 0,6827, soit 68,27 % (règle des 68 %). 3) 500 × 0,0228 ≈ 11,4 : environ 11 candidats. 4) Les 16 % meilleurs correspondent à P(X > seuil) ≈ 0,16, donc Φ(z) ≈ 0,84, soit z ≈ 1 : seuil ≈ 60 + 1 × 12 = 72. (Cohérent avec la question 2 : au-dessus de 72, il reste environ (1 − 0,6827)/2 ≈ 15,9 % des candidats.)

Exercice 3

Un sondage auprès de 100 étudiants indique que 72 % sont satisfaits de la bibliothèque universitaire. 1) Construis l'intervalle de confiance à 95 % pour la proportion réelle d'étudiants satisfaits. 2) Le responsable du service communication veut titrer « 72 % des étudiants satisfaits » : que doit-il écrire honnêtement ? 3) De combien faudrait-il multiplier la taille de l'échantillon pour diviser la marge par deux ?

✔ Corrigé
1) f = 0,72 ; erreur-type = √(0,72 × 0,28/100) = √0,002016 ≈ 0,0449 ; marge = 1,96 × 0,0449 ≈ 0,088. IC à 95 % : [0,632 ; 0,808], soit entre environ 63,2 % et 80,8 %. 2) Formulation honnête : « Selon un sondage auprès de 100 étudiants, la proportion d'étudiants satisfaits de la bibliothèque est estimée entre 63 % et 81 % environ (intervalle de confiance à 95 %, marge ± 9 points) ». Le chiffre seul de 72 % est l'estimation ponctuelle, sans sa précision : publié seul, il sur-vend le résultat. 3) La marge varie en 1/√n : la diviser par 2 exige de multiplier n par 4, soit 400 étudiants (la marge passerait à environ ± 4,4 points).

QCM d'évaluation

Choisis la bonne réponse pour chaque question. Les corrigés détaillés se trouvent juste après le QCM : ne les regarde qu'après avoir répondu à tout.

1. La médiane d'une série statistique est…

   A) La valeur la plus fréquente de la série

   B) La valeur qui partage la série triée en deux moitiés égales

   C) La moyenne des valeurs extrêmes

2. On ajoute 5 à TOUTES les valeurs d'une série. Son écart-type…

   A) Augmente de 5

   B) Est multiplié par 5

   C) Reste inchangé

3. Un coefficient de corrélation r = −0,9 indique…

   A) Un lien linéaire fort et décroissant entre les deux variables

   B) Un lien linéaire faible

   C) Que la première variable cause la seconde

4. Pour une variable suivant la loi normale, la proportion de valeurs dans [μ − σ ; μ + σ] vaut environ…

A) 50 %

B) 68 %

C) 95 %

5. Un intervalle de confiance à 95 % pour une moyenne signifie que…

A) La moyenne vraie a 95 % de chances d'être dans cet intervalle précis

B) Il y a 95 % des observations dans l'intervalle

C) La méthode de construction capture la vraie valeur dans 95 % des échantillons

6. Dans un test d'hypothèses, l'erreur de première espèce consiste à…

A) Rejeter H_0 alors qu'elle est vraie

B) Ne pas rejeter H_0 alors qu'elle est fausse

C) Se tromper dans le calcul de la statistique

7. Si la taille d'un échantillon est multipliée par 4, l'erreur-type de la moyenne est…

A) Divisée par 4

B) Inchangée

C) Divisée par 2

8. Pour estimer la variance d'une population à partir d'un échantillon, la somme des carrés des écarts se divise par…

A) n

B) n − 1

C) √n

9. Dans un test au seuil de 5 %, on obtient une p-value de 0,03. La décision est…

A) On ne peut pas conclure

B) On rejette H_0

C) On accepte définitivement H_0

10. La droite des moindres carrés passe toujours par le point…

A) (0 ; 0)

B) ($\bar{x}$; $\bar{y}$), le point moyen du nuage

C) Le point du nuage d'abscisse maximale

Corrigés du QCM

1. Réponse B — La médiane est un paramètre de position robuste : 50 % des valeurs sont en dessous, 50 % au-dessus. La valeur la plus fréquente est le mode.

2. Réponse C — Décaler toutes les valeurs translate la série sans changer les écarts entre elles : la moyenne augmente de 5, mais la dispersion est identique.

3. Réponse A — |r| proche de 1 = lien linéaire fort ; le signe négatif donne le sens décroissant. Et même fort, r ne prouve jamais une causalité.

4. Réponse B — C'est la règle des 68–95–99,7 : 68 % à ±1σ, 95 % à ±2σ, 99,7 % à ±3σ.

5. Réponse C — Le niveau de confiance qualifie la procédure : répétée sur de nombreux échantillons, elle produit des intervalles contenant le paramètre dans 95 % des cas.

6. Réponse A — C'est la « fausse alerte », dont le risque est le seuil α choisi. Ne pas rejeter un H_0 faux est l'erreur de seconde espèce (risque β).

7. Réponse C — L'erreur-type vaut $\sigma/\sqrt{n}$: multiplier n par 4 multiplie $\sqrt{n}$ par 2, donc divise l'erreur-type par 2.

8. Réponse B — La variance d'échantillon s^2 divise par $n - 1$ pour corriger la sous-estimation systématique ; la division par n est réservée à la description d'une population complète.

9. Réponse B — p-value (0,03) ≤ α (0,05) : le résultat est suffisamment improbable sous H_0 pour la rejeter au seuil choisi.

10. Réponse B — C'est une propriété de construction : $b = \bar{y} - a\cdot\bar{x}$ garantit que le point moyen appartient à la droite.

Résumé — les notions importantes

• Décrire avant d'inférer : tableau d'effectifs/fréquences/cumulés et graphique adapté au type de variable (bâtons, circulaire, histogramme).

• Position (moyenne, médiane, quartiles, mode) et dispersion (étendue, écart interquartile, variance, écart-type, coefficient de variation) se donnent toujours ensemble, en annonçant la convention : variance ÷ N pour une population complète, ÷ (n − 1) pour un échantillon (s^2).

• Régression : droite des moindres carrés $\hat{y} = ax + b$ passant par $(\bar{x} ; \bar{y})$; $r \in [-1 ; 1]$ mesure le lien linéaire, sans jamais prouver une causalité.

• Loi normale : centrer-réduire $z = (x - \mu)/\sigma$ et lire $\Phi(z)$; la moyenne d'échantillon suit $\approx N(\mu ; \sigma/\sqrt{n})$ — l'erreur-type commande toute la précision.

• Intervalle de confiance : estimation ± marge, avec niveau annoncé (95 % : coefficient 1,96) ; la taille d'échantillon se dimensionne à partir de la marge visée.

• Test d'hypothèses : H_0/H_1 et seuil fixés d'avance, décision par valeur critique ou p-value ≤ α, erreurs de type I (α) et de type II (β) assumées et commentées.

• Tableur et Python (statistics, pandas) automatisent l'analyse : la rigueur reste humaine — inspection des données, conventions alignées, résultats recoupés.

Fiches de révision express

Chaque fiche reprend les points « À retenir » d'une leçon. Relis-les la veille d'un contrôle : cinq minutes par fiche suffisent.

Fiche 1 — Rappels : séries statistiques et représentations graphiques
La somme des effectifs vaut N, celle des fréquences vaut 1 (ou 100 %) : deux contrôles gratuits de tout tableau. ; Les cumulés n'ont de sens que si les modalités sont ordonnées (jamais pour une variable qualitative nominale). ; Histogramme = variable continue en classes, rectangles collés ; bâtons = modalités séparées.

Fiche 2 — Paramètres de position et paramètres de dispersion
Moyenne et médiane se complètent : si elles sont très différentes, la série est asymétrique ou contient des valeurs extrêmes. ; Variance et écart-type : toujours annoncer si l'on divise par N ou par n − 1. ; Le coefficient de variation, sans unité, est le seul paramètre qui permet de comparer deux dispersions de nature différente.

Fiche 3 — Régression linéaire et corrélation
Construis toujours le tableau des sommes (Σx, Σy, Σxy, Σx^2, Σy^2) avant d'appliquer les formules : c'est là que naissent les erreurs. ; La pente a a une unité (celle de y par unité de x) et une interprétation concrète ; b n'en a pas toujours. ; r proche de 0 ne signifie pas « aucun lien », mais « aucun lien linéaire » ; et un r élevé ne prouve pas une cause.

Fiche 4 — La loi normale et l'échantillonnage
Toujours centrer-réduire avant de lire la table : la table ne connaît que N(0 ; 1). ; $\Phi(z)$ donne une probabilité CUMULÉE à gauche ; un intervalle se calcule par une différence de deux Φ. ; L'erreur-type $\sigma/\sqrt{n}$ gouverne toute l'inférence : elle relie la précision d'un échantillon à sa taille.

Fiche 5 — Estimation et intervalles de confiance
Un intervalle de confiance sans son niveau (90 %, 95 %, 99 %) est incomplet ; 95 % est le standard. ; La marge diminue en $1/\sqrt{n}$: la quadrupler exige 16 fois plus d'observations — la précision se paie cher. ; Pour une proportion, le pire cas p = 0,5 donne la taille d'échantillon prudente, valable quelle que soit la vraie valeur.

Fiche 6 — Tests d'hypothèses : initiation
La p-value n'est pas « la probabilité que H_0 soit vraie » : c'est la probabilité des données (ou plus extrêmes) SI H_0 est vraie. ; « Ne pas rejeter H_0 » ≠ « H_0 est vraie » : sans puissance suffisante, le test peut ne rien voir. ; Le caractère unilatéral ou bilatéral se décide avant l'analyse, sinon le seuil annoncé est mensonger.

Fiche 7 — Analyse de données avec le tableur et avec Python
Avant de calculer : inspecter (types, manquants, aberrants) — un résultat propre sur des données sales reste faux. ; pandas et le tableur doivent raconter la même histoire ; tout écart vient presque toujours de la convention d'écart-type. ; Le script est la documentation reproductible de l'analyse ; le classeur seul ne dit pas comment il a été produit.

Vidéos associées aux leçons

Ces vidéos, en français, complètent les leçons. Liens vérifiés au moment de la publication de ce document.

Leçon 3 — 15. Le coefficient de corrélation de Pearson

Chaîne : Eric Lombardot · Langue : Français · Niveau : Intermédiaire

Principe, calcul pas à pas et interprétation du coefficient de corrélation de Pearson et du coefficient de détermination r^2, avec un exercice d'application complet. Le

prolongement direct de la leçon 3, au niveau universitaire.

https://www.youtube.com/watch?v=ciqcsWqIHIQ

Leçon 3 — 08 Cours de Statistique : Ajustement affine par la méthode des moindres carrés.

Chaîne : Je vise mon bac · Langue : Français · Niveau : Débutant à intermédiaire

L'ajustement affine expliqué simplement : nuage de points, droite de régression par les moindres carrés et coefficient de corrélation, avec la méthode de calcul du tableau des sommes utilisée dans ce cours.

https://www.youtube.com/watch?v=vTVc1FneSp4

Leçon 4 — Loi normale : calculer le pourcentage de vis défectueuses | Exercice corrigé

Chaîne : PVegnrt159 · Langue : Français · Niveau : Intermédiaire

Un exercice corrigé de contrôle qualité : identifier μ et σ, centrer-réduire les valeurs, lire la table de la loi normale et interpréter le pourcentage obtenu, exactement la démarche de la leçon 4.

https://www.youtube.com/watch?v=UyRMqP7L2CY

Leçon 5 — Proba-stats : Chapitre 10 Statistiques inférentielles - Partie 1 Estimation et échantillonnage

Chaîne : Maths DUT info Bourg-en-Bresse · Langue : Français · Niveau : Intermédiaire

Cours de DUT Informatique sur l'échantillonnage et l'estimation : estimateurs, biais et intervalles de confiance, qui prépare exactement les leçons 5 et 6 de ce cours.

https://www.youtube.com/watch?v=GBwIpt27S-M

Leçon 7 — PANDAS PYTHON Français - Introduction + Analyse du Titanic (17/30)

Chaîne : Machine Learnia · Langue : Français · Niveau : Débutant à intermédiaire

Introduction à pandas en français : charger un DataFrame, l'inspecter, obtenir ses statistiques descriptives avec describe() et produire des graphiques, sur un jeu de données réel.

https://www.youtube.com/watch?v=zZkNOdBWgFQ

Sources et références

- Programme officiel Licence Informatique, Université IAM (Institut Africain de Management), Bamako — vérifier les intitulés d'UE auprès du secrétariat pédagogique.
- Documentation Python : module statistics (docs.python.org/fr/3/library/statistics.html) et bibliothèque pandas (pandas.pydata.org) pour l'analyse de données.
- Table de la loi normale centrée réduite (fonction de répartition Φ) — reproduite dans tous les formulaires de probabilités et statistiques de niveau Licence.

• Schwartz, D. — « Méthodes statistiques à l'usage des médecins et des biologistes » (Flammarion) : une présentation classique et rigoureuse de l'estimation et des tests, accessible dès la L2.

• Les vidéos listées dans la section « Vidéos associées aux leçons » de ce document (liens vérifiés à la publication).

Fin du cours — Bronbah Tech, Bibliothèque Universitaire IAM. Bon courage pour tes révisions !

Mes notes

Utilise ces pages pour recopier les définitions, refaire les calculs et noter tes questions pour le prochain cours.